UNIVERSIDADE PRESBITERIANA MACKENZIE

Series Temporais

Previsão de vendas - Amazon

Vitor Assunção Rocha - RA 10440984

São Paulo

2026

SUMÁRIO

1. Introdução..... 2
2. Área de Atuação..... 2
3. Objetivo do Projeto.....2
4. Apresentação dos Dados e Metadados.....3
5. Referencial Teórico.....4
6. Pipeline da Solução.....5
7. Cronograma.....6
8. Referências.....7

1. Introdução

O presente projeto tem como objetivo desenvolver um modelo de previsão de vendas utilizando técnicas de análise de séries temporais aplicadas a dados de vendas da Amazon. A análise de séries temporais permite identificar padrões ao longo do tempo, como tendências, sazonalidades e variações cíclicas, possibilitando a antecipação de comportamentos futuros.

Com o crescimento do comércio eletrônico e o aumento do volume de dados gerados diariamente, modelos preditivos tornam-se ferramentas estratégicas para planejamento logístico, gestão de estoque e tomada de decisão baseada em dados.

Neste contexto, o projeto busca aplicar métodos estatísticos e de aprendizado de máquina para prever a demanda futura de produtos, contribuindo para otimização operacional e redução de custos.

2. Área de Atuação

O projeto está inserido na área de **Ciência de Dados aplicada ao varejo digital (E-commerce)**, com foco em análise preditiva e inteligência analítica.

A previsão de vendas é amplamente utilizada por empresas como a Amazon para:

- Planejamento de estoque
- Previsão de demanda
- Otimização da cadeia de suprimentos
- Estratégias comerciais

3. Objetivo do Projeto

O objetivo principal é desenvolver um modelo capaz de prever vendas futuras com base em dados históricos utilizando técnicas de séries temporais.

Objetivos específicos:

- Analisar o comportamento temporal das vendas;
- Identificar tendências e sazonalidades;
- Preparar e tratar dados temporais;
- Treinar modelos preditivos;
- Avaliar a precisão das previsões.

O projeto busca demonstrar como técnicas de previsão podem apoiar decisões estratégicas no varejo online.

Abaixo segue o link do github deste projeto:

https://github.com/VtrRocha/Projeto-Aplicado-4-

4. Apresentação dos Dados e Metadados

O dataset utilizado neste projeto contém informações históricas de vendas provenientes de uma base simulando operações de e-commerce da Amazon. A base possui registros detalhados sobre pedidos, produtos, clientes e transações financeiras, permitindo análises temporais e construção de modelos preditivos de vendas.

Visão Geral do Dataset

- Total de registros: **100.000 pedidos**
- Total de colunas: **20 variáveis**
- Período temporal: **01/01/2020 até 29/12/2024**
- Tipo de dados: estruturado (CSV)

https://www.kaggle.com/datasets/rohiteng/amazon-sales-dataset

5. Referencial Teórico

Séries Temporais

Uma série temporal é uma sequência de observações coletadas ao longo do tempo em intervalos regulares. Sua análise baseia-se na identificação de componentes estruturais: **tendência** (movimento de longo prazo), **sazonalidade** (padrões cíclicos de curto prazo) e **resíduo** (variações aleatórias) (BOX; JENKINS; REINSEL, 2015). A decomposição da série nessas componentes é um passo essencial antes da modelagem preditiva.

Modelos ARIMA e SARIMA

O modelo **ARIMA** (AutoRegressive Integrated Moving Average) combina processos autorregressivos (AR), diferenciação para estacionarização (I) e médias móveis (MA), sendo parametrizado por (p, d, q). Sua extensão sazonal, o **SARIMA**, incorpora termos sazonais (P, D, Q, s), tornando-o adequado para séries com padrões periódicos. Esses modelos são amplamente utilizados em previsão de demanda no varejo (HYNDMAN; ATHANASOPOULOS, 2021).

Prophet

Desenvolvido pelo Facebook (atual Meta), o **Prophet** é um modelo aditivo de séries temporais especialmente robusto a dados faltantes, outliers e mudanças de tendência. Modela explicitamente feriados e sazonalidades múltiplas (TAYLOR; LETHAM, 2018), sendo amplamente adotado em aplicações de negócios por sua facilidade de uso e interpretabilidade.

Trabalhos Correlacionados

Estudos anteriores aplicaram modelos de séries temporais à previsão de vendas no e-commerce com resultados promissores. Fildes et al. (2019) demonstraram que modelos SARIMA superam métodos ingênuos (naive) em horizontes curtos de previsão para produtos de alta rotatividade. Já Bandara et al. (2020) compararam ARIMA, Prophet e redes neurais recorrentes (LSTM), concluindo que modelos estatísticos clássicos apresentam desempenho

competitivo quando o volume de dados históricos é limitado, enquanto modelos de deep learning se destacam com séries longas e múltiplas variáveis.

Métricas de Avaliação

As principais métricas utilizadas para avaliar modelos de forecasting são: **MAE** (Mean Absolute Error), que mede o erro absoluto médio; **RMSE** (Root Mean Squared Error), mais sensível a grandes erros; e **MAPE** (Mean Absolute Percentage Error), que expressa o erro em termos percentuais, facilitando a comparação entre séries de diferentes escalas (HYNDMAN; ATHANASOPOULOS, 2021).

6. Pipeline da Solução

O pipeline proposto para a resolução do problema de previsão de vendas é composto pelas seguintes etapas:

Etapa 1 — Coleta e Carregamento dos Dados

Carregamento do dataset Amazon.csv (≈100.000 registros) utilizando a biblioteca pandas. Verificação inicial das dimensões, tipos de dados e valores ausentes.

Etapa 2 — Análise Exploratória dos Dados (EDA)

Distribuição temporal dos pedidos (por dia, semana e mês); análise por categoria de produto, método de pagamento e status do pedido; identificação visual de tendências, sazonalidades e outliers; e decomposição da série temporal (tendência + sazonalidade + resíduo).

Etapa 3 — Pré-processamento

Conversão da coluna OrderDate para o tipo datetime; agregação dos dados em séries temporais de TotalAmount e Quantity nas granularidades diária e semanal; tratamento de datas sem registros (preenchimento com zero ou interpolação); teste de estacionariedade (ADF — Augmented Dickey-Fuller) e diferenciação quando necessário; e divisão dos dados em conjuntos de treino e teste (últimas 8 semanas para teste).

Etapa 4 — Modelagem

Serão desenvolvidos e comparados os seguintes modelos: (1) **ARIMA/SARIMA** — via biblioteca statsmodels, com seleção automática de parâmetros por AIC; e (2) **Prophet** — com modelagem explícita de sazonalidades e feriados. Para cada modelo serão ajustados hiperparâmetros e geradas previsões no horizonte de 4 a 8 semanas.

Etapa 5 — Avaliação dos Modelos

Cálculo das métricas MAE, RMSE e MAPE sobre o conjunto de teste; análise dos resíduos (autocorrelação, distribuição); comparação visual entre valores reais e previstos; e seleção do modelo com melhor desempenho.

Etapa 6 — Geração de Previsões e Interpretação

Geração de previsões futuras com o modelo selecionado; visualização das previsões com intervalos de confiança; interpretação dos resultados no contexto de negócio (picos de demanda, tendências de crescimento); e documentação e conclusões.

7. Cronograma

Etapa	Data	Atividades	Milestone
Concepção do produto	1 de Março	Escolher a base de dados. Definir o cronograma do projeto. Elaborar o documento inicial.	Definição inicial dos objetivos e entendimento dos dados
Definição do Produto Analítico	29 de Março	Analisar a base de dados. Limpar e preparar a base de dados. Escolher a técnica para treinamento do modelo. Construir uma prova de conceito. Definir métricas de avaliação de desempenho	Definição clara do produto analítico
Metodologia	26 de Abril	Implementar a técnica proposta. Ajustar o pipeline de dados. Documentar os passos implementados, a técnica e a forma de avaliação de desempenho do modelo	Esqueleto do relatório e visualizações principais concluídos
Resultados e Conclusão	31 de Maio	Organizar e documentar os resultados alcançados. Finalizar a documentação do projeto. Entregar os materiais produzidos e a apresentação do projeto.	Relatório final entregue e apresentação realizada

8. Referências

BANDARA, K.; BERGMEIR, C.; SMYL, S. Forecasting across time series databases using recurrent neural networks on groups of similar series. **Expert Systems with Applications**, v. 140, p. 112855, 2020.

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. **Time Series Analysis: Forecasting and Control**. 5. ed. Hoboken: Wiley, 2015.

FILDES, R.; MA, S.; KOLASSA, S. Retail forecasting: Research and practice. **International Journal of Forecasting**, v. 35, n. 4, p. 1327–1356, 2019.

HYNDMAN, R. J.; ATHANASOPOULOS, G. **Forecasting: Principles and Practice**. 3. ed. Melbourne: OTexts, 2021. Disponível em: https://otexts.com/fpp3/. Acesso em: 03 abr. 2026.

TAYLOR, S. J.; LETHAM, B. Forecasting at scale. **The American Statistician**, v. 72, n. 1, p. 37–45, 2018.

ROHITENG. Amazon Sales Dataset. Kaggle, 2023. Disponível em: https://www.kaggle.com/datasets/rohiteng/amazon-sales-dataset. Acesso em: 03 abr. 2026.