UNIVERSIDADE PRESBITERIANA MACKENZIE

Ciência de Dados EaD – Projeto Aplicado IV

Séries Temporais

Previsão de Vendas — Dataset Amazon

Entrega 3

Vitor Assunção Rocha – RA 10440984

São Paulo
2026

SUMÁRIO

1. Introdução 2
2. Área de Atuação 2
3. Objetivo do Projeto 2
4. Apresentação dos Dados e Metadados 3
5. Referencial Teórico 4
6. Pipeline da Solução 5
7. EDA e Pré-processamento dos Dados 6
8. Modelo Base 7
9. Cronograma 8
10. Referências 9

1. Introdução

O presente projeto tem como objetivo desenvolver um modelo de previsão de vendas utilizando técnicas de análise de séries temporais aplicadas a dados de vendas da Amazon. A análise de séries temporais permite identificar padrões ao longo do tempo, como tendências, sazonalidades e variações cíclicas, possibilitando a antecipação de comportamentos futuros.

Com o crescimento do comércio eletrônico e o aumento do volume de dados gerados diariamente, modelos preditivos tornam-se ferramentas estratégicas para planejamento logístico, gestão de estoque e tomada de decisão baseada em dados.

Neste contexto, o projeto busca aplicar métodos estatísticos e de aprendizado de máquina para prever a demanda futura de produtos, contribuindo para otimização operacional e redução de custos.

2. Área de Atuação

Ciência de Dados aplicada ao varejo digital (E-commerce), com foco em análise preditiva e inteligência analítica.

A previsão de vendas é amplamente utilizada por empresas como a Amazon para:

- Planejamento de estoque
- Previsão de demanda
- Otimização da cadeia de suprimentos
- Estratégias comerciais

3. Objetivo do Projeto

O objetivo principal é desenvolver um modelo capaz de prever vendas futuras com base em dados históricos utilizando técnicas de séries temporais.

Objetivos específicos:

- Analisar o comportamento temporal das vendas;
- Identificar tendências e sazonalidades;
- Preparar e tratar dados temporais;
- Treinar modelos preditivos;
- Avaliar a precisão das previsões.

O projeto busca demonstrar como técnicas de previsão podem apoiar decisões estratégicas no varejo online.

Repositório GitHub: https://github.com/VtrRocha/Projeto-Aplicado-4-

4. Apresentação dos Dados e Metadados

O dataset utilizado neste projeto contém informações históricas de vendas provenientes de uma base simulando operações de e-commerce da Amazon. A base possui registros detalhados sobre pedidos, produtos, clientes e transações financeiras, permitindo análises temporais e construção de modelos preditivos de vendas.

Visão Geral do Dataset

- **Total de registros:** 100.000 pedidos
- **Total de colunas:** 20 variáveis
- **Período temporal:** 2022 a 2023
- **Tipo de dados:** estruturado (CSV)

Fonte: https://www.kaggle.com/datasets/rohiteng/amazon-sales-dataset

5. Referencial Teórico

Séries Temporais

Uma série temporal é uma sequência de observações coletadas ao longo do tempo em intervalos regulares. Sua análise baseia-se na identificação de componentes estruturais: **tendência** (movimento de longo prazo), **sazonalidade** (padrões cíclicos de curto prazo) e **resíduo** (variações aleatórias) (BOX; JENKINS; REINSEL, 2015). A decomposição da série nessas componentes é um passo essencial antes da modelagem preditiva.

Modelos ARIMA e SARIMA

O modelo **ARIMA** (AutoRegressive Integrated Moving Average) combina processos autorregressivos (AR), diferenciação para estacionarização (I) e médias móveis (MA), sendo parametrizado por (p, d, q). Sua extensão sazonal, o **SARIMA**, incorpora termos sazonais (P, D, Q, s), tornando-o adequado para séries com padrões periódicos. Esses modelos são amplamente utilizados em previsão de demanda no varejo (HYNDMAN; ATHANASOPOULOS, 2021).

Prophet

Desenvolvido pelo Facebook (atual Meta), o **Prophet** é um modelo aditivo de séries temporais especialmente robusto a dados faltantes, outliers e mudanças de tendência. Modela explicitamente feriados e sazonalidades múltiplas (TAYLOR; LETHAM, 2018), sendo amplamente adotado em aplicações de negócios por sua facilidade de uso e interpretabilidade.

Trabalhos Correlacionados

Estudos anteriores aplicaram modelos de séries temporais à previsão de vendas no e-commerce com resultados promissores. Fildes et al. (2019) demonstraram que modelos SARIMA superam métodos ingênuos (naive) em horizontes curtos de previsão para produtos de alta rotatividade. Já Bandara et al. (2020) compararam ARIMA, Prophet e redes neurais recorrentes (LSTM), concluindo que modelos estatísticos clássicos apresentam desempenho competitivo quando o volume de dados históricos é limitado, enquanto modelos de deep learning se destacam com séries longas e múltiplas variáveis.

Métricas de Avaliação

As principais métricas utilizadas para avaliar modelos de forecasting são: **MAE** (Mean Absolute Error), que mede o erro absoluto médio; **RMSE** (Root Mean Squared Error), mais sensível a grandes erros; e **MAPE** (Mean Absolute Percentage Error), que expressa o erro em termos percentuais, facilitando a comparação entre séries de diferentes escalas (HYNDMAN; ATHANASOPOULOS, 2021).

6. Pipeline da Solução

O pipeline proposto para a resolução do problema de previsão de vendas é composto pelas seguintes etapas:

Etapa 1 — Coleta e Carregamento dos Dados

Carregamento do dataset Amazon.csv (≈100.000 registros) utilizando a biblioteca pandas. Verificação inicial das dimensões, tipos de dados e valores ausentes.

Etapa 2 — Análise Exploratória dos Dados (EDA)

Distribuição temporal dos pedidos (por dia, semana e mês); análise por categoria de produto, método de pagamento e status do pedido; identificação visual de tendências, sazonalidades e outliers; e decomposição da série temporal (tendência + sazonalidade + resíduo).

Etapa 3 — Pré-processamento

Conversão da coluna OrderDate para o tipo datetime; agregação dos dados em séries temporais de TotalAmount e Quantity nas granularidades diária e semanal; tratamento de datas sem registros; teste de estacionariedade (ADF) e diferenciação quando necessário; e divisão dos dados em conjuntos de treino e teste (últimas 8 semanas para teste).

Etapa 4 — Modelagem

Serão desenvolvidos e comparados os seguintes modelos: (1) **ARIMA/SARIMA** — via biblioteca statsmodels, com seleção automática de parâmetros por AIC; e (2) **Prophet** — com modelagem explícita de sazonalidades e feriados. Para cada modelo serão ajustados hiperparâmetros e geradas previsões no horizonte de 4 a 8 semanas.

Etapa 5 — Avaliação dos Modelos

Cálculo das métricas MAE, RMSE e MAPE sobre o conjunto de teste; análise dos resíduos (autocorrelação, distribuição); comparação visual entre valores reais e previstos; e seleção do modelo com melhor desempenho.

Etapa 6 — Geração de Previsões e Interpretação

Geração de previsões futuras com o modelo selecionado; visualização das previsões com intervalos de confiança; interpretação dos resultados no contexto de negócio (picos de demanda, tendências de crescimento); e documentação e conclusões.

7. EDA e Pré-processamento dos Dados

Esta seção apresenta as principais etapas de exploração e preparação dos dados realizadas para a Entrega 3, constituindo a base para a modelagem preditiva.

7.1 Qualidade e Integridade dos Dados

A análise inicial do dataset confirmou a ausência de valores nulos e registros duplicados, indicando boa qualidade da base. Foram identificadas, porém, inconsistências semânticas de natureza sintética:

- **Anomalia geográfica:** registros com State = 'DC' associados ao Country = 'India', incompatíveis com a localização real de Washington D.C.;
- **Anomalia de categoria:** produtos do tipo 'Drone' classificados na categoria 'Books', evidenciando ruído na rotulagem do dataset.

Essas inconsistências são características de datasets sintéticos e foram documentadas sem impacto direto sobre a série temporal de faturamento agregado, variável-alvo do projeto.

7.2 Agregação Temporal

Após a conversão da coluna OrderDate para o tipo datetime nativo do pandas, os pedidos com status diferente de 'Cancelled' foram agregados em duas granularidades:

- **Série Diária:** soma do TotalAmount por dia, com preenchimento de zeros para dias sem registros.
- **Série Semanal:** resample semanal (W) da série diária, resultando em 104 semanas para o período 2022–2023.

A série semanal foi selecionada como granularidade primária para a modelagem, pois reduz o ruído diário e evidencia os padrões sazonais com maior clareza.

7.3 Decomposição e Estacionariedade

A decomposição clássica aditiva da série semanal (período = 52 semanas) revelou:

- **Tendência:** leve crescimento de faturamento ao longo de 2022–2023;
- **Sazonalidade:** padrões cíclicos anuais com picos em períodos específicos;
- **Resíduo:** variação aleatória sem padrão sistemático evidente.

O teste **ADF (Augmented Dickey-Fuller)** aplicado à série original indicou não-estacionariedade (p-valor > 0,05). Após aplicação da 1ª diferença, a série tornou-se estacionária (p-valor < 0,05), validando o parâmetro d = 1 para o modelo ARIMA.

7.4 Divisão Treino / Teste

Os dados foram divididos em:

- **Treino:** semanas de 01/01/2022 a 03/11/2023 (96 semanas)
- **Teste:** últimas 8 semanas de novembro–dezembro/2023

Esta divisão permite avaliar o desempenho preditivo do modelo em um horizonte de curto prazo realista (≈2 meses).

8. Modelo Base

O **modelo ARIMA** (AutoRegressive Integrated Moving Average) foi implementado como modelo base para a previsão do faturamento semanal, utilizando a biblioteca statsmodels. A seleção dos parâmetros (p, d, q) foi realizada por meio de grid search com minimização do critério **AIC** (Akaike Information Criterion).

8.1 Seleção de Parâmetros

O grid search avaliou todas as combinações de $p \in \{0,1,2\}$, $d \in \{0,1\}$ e $q \in \{0,1,2\}$, totalizando 18 configurações. O modelo com menor AIC foi selecionado para geração das previsões.

8.2 Avaliação dos Resultados

O modelo selecionado foi aplicado sobre o conjunto de teste (8 semanas) e avaliado pelas seguintes métricas:

- **MAE** (Mean Absolute Error): desvio absoluto médio por semana prevista;
- **RMSE** (Root Mean Squared Error): mais sensível a erros pontuais elevados;
- **MAPE** (Mean Absolute Percentage Error): erro percentual relativo ao volume de vendas.

8.3 Diagnóstico de Resíduos

O diagnóstico dos resíduos do modelo ajustado avalia:

- Ausência de autocorrelação nos resíduos (função ACF próxima de zero nos lags > 0);
- Distribuição dos resíduos aproximadamente normal;
- Homocedasticidade (variância constante ao longo do tempo).

O cumprimento dessas premissas valida a adequação do modelo ARIMA aos dados e garante a confiabilidade dos intervalos de previsão.

8.4 Próximos Passos

Com o modelo ARIMA estabelecido como baseline, a próxima etapa (Entrega Final) consiste na implementação do modelo Prophet, seguida de avaliação comparativa direta entre os dois modelos nas mesmas métricas e no mesmo conjunto de teste, e na geração de previsões para horizontes futuros com interpretação orientada ao negócio.

9. Cronograma

Etapa	Data	Atividades	Milestone
Concepção do produto	01/03/2026	Escolha da base de dados. Definição do cronograma. Elaboração do documento inicial.	Definição inicial dos objetivos e entendimento dos dados
Definição do Produto Analítico	29/03/2026	Análise exploratória inicial. Limpeza e preparação dos dados. Escolha da técnica e definição de métricas.	Definição clara do produto analítico
Metodologia – EDA e Modelo Base	26/04/2026	Pré-processamento completo das séries temporais. Implementação do modelo ARIMA (modelo base). Avaliação MAE/RMSE/MAPE.	EDA concluída. Modelo base implementado e avaliado.
Resultados e Conclusão	31/05/2026	Implementação do Prophet. Comparação de modelos. Previsões futuras. Documentação final e apresentação.	Relatório final entregue e apresentação realizada

10. Referências

BANDARA, K.; BERGMEIR, C.; SMYL, S. Forecasting across time series databases using recurrent neural networks on groups of similar series. ***Expert Systems with Applications***, v. 140, p. 112855, 2020.

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. ***Time Series Analysis: Forecasting and Control***. 5. ed. Hoboken: Wiley, 2015.

FILDES, R.; MA, S.; KOLASSA, S. Retail forecasting: Research and practice. ***International Journal of Forecasting***, v. 35, n. 4, p. 1327–1356, 2019.

HYNDMAN, R. J.; ATHANASOPOULOS, G. ***Forecasting: Principles and Practice***. 3. ed. Melbourne: OTexts, 2021. Disponível em: https://otexts.com/fpp3/.

TAYLOR, S. J.; LETHAM, B. Forecasting at scale. ***The American Statistician***, v. 72, n. 1, p. 37–45, 2018.

ROHITENG. Amazon Sales Dataset. Kaggle, 2023. Disponível em: https://www.kaggle.com/datasets/rohiteng/amazon-sales-dataset. Acesso em: 03 abr. 2026.