

UNIVERSIDADE PRESBITERIANA MACKENZIE

Ciência de Dados EaD — Projeto Aplicado IV

Séries Temporais

Previsão de Vendas — Dataset Amazon

Entrega 4

Vitor Assunção Rocha — RA 10440984

São Paulo

2026

SUMÁRIO

1. Resumo	2
2. Introdução	2
3. Referencial Teórico	3
4. Diagrama de Solução (Pipeline)	4
5. EDA e Pré-processamento dos Dados	5
5.1 Qualidade e Integridade dos Dados	5
5.2 Agregação Temporal	5
5.3 Decomposição e Estacionariedade	6
5.4 Divisão Treino / Teste	6
6. Modelos	6
6.1 Modelo Base — ARIMA	6
6.2 Modelo Avançado — Prophet	8
7. Resultados	9
8. Discussão e Conclusão	10
9. Apresentação	11
10. Referências	11

1. Resumo

O crescimento acelerado do comércio eletrônico gera volumes massivos de dados históricos de transações que, quando bem explorados, permitem antecipar o comportamento futuro das vendas. Este projeto aborda o problema de previsão de faturamento semanal em uma plataforma de e-commerce, utilizando o Amazon Sales Dataset (~100 mil registros de pedidos de 2022 a 2023). A relevância da solução reside no suporte à tomada de decisão estratégica: otimização de estoques, planejamento logístico e alocação de campanhas promocionais. A metodologia empregada segue um pipeline de Ciência de Dados que compreende análise exploratória, pré-processamento e decomposição de séries temporais, implementação e comparação de dois modelos preditivos — ARIMA (seleção automática de parâmetros via critério AIC) e Prophet (Facebook/Meta) — e avaliação por meio das métricas MAE, RMSE e MAPE. Os resultados indicam que o Prophet apresentou desempenho superior ao ARIMA na série semanal de faturamento, capturando com maior fidelidade a sazonalidade e a tendência de crescimento presentes nos dados.

2. Introdução

O presente projeto tem como objetivo desenvolver um modelo de previsão de vendas utilizando técnicas de análise de séries temporais aplicadas a dados de vendas da Amazon. A análise de séries temporais permite identificar padrões ao longo do tempo, como tendências, sazonalidades e variações cíclicas, possibilitando a antecipação de comportamentos futuros.

Com o crescimento do comércio eletrônico e o aumento do volume de dados gerados diariamente, modelos preditivos tornam-se ferramentas estratégicas para planejamento logístico, gestão de estoque e tomada de decisão baseada em dados. Neste contexto, o projeto busca aplicar métodos estatísticos e de aprendizado de máquina para prever a demanda futura de produtos, contribuindo para otimização operacional e redução de custos.

Área de Atuação

Ciência de Dados aplicada ao varejo digital (E-commerce), com foco em análise preditiva e inteligência analítica. A previsão de vendas é amplamente utilizada por empresas como a Amazon para planejamento de estoque, previsão de demanda, otimização da cadeia de suprimentos e estratégias comerciais.

Objetivo do Projeto

O objetivo principal é desenvolver um modelo capaz de prever vendas futuras com base em dados históricos utilizando técnicas de séries temporais.

Objetivos específicos:

- Analisar o comportamento temporal das vendas;
- Identificar tendências e sazonalidades;
- Preparar e tratar dados temporais;
- Treinar e comparar modelos preditivos (ARIMA e Prophet);

- Avaliar a precisão das previsões e selecionar o melhor modelo.

Repositório GitHub: <https://github.com/VtrRocha/Projeto-Aplicado-4->

Apresentação dos Dados e Metadados

O dataset utilizado neste projeto contém informações históricas de vendas provenientes de uma base simulando operações de e-commerce da Amazon. A base possui registros detalhados sobre pedidos, produtos, clientes e transações financeiras, permitindo análises temporais e construção de modelos preditivos de vendas.

- Total de registros: 100.000 pedidos
- Total de colunas: 20 variáveis (OrderID, OrderDate, CustomerID, ProductName, Category, Brand, Quantity, UnitPrice, Discount, Tax, ShippingCost, TotalAmount, PaymentMethod, OrderStatus, City, State, Country, entre outras)
- Período temporal: 2022 a 2023
- Tipo de dados: estruturado (CSV)

Fonte: <https://www.kaggle.com/datasets/rohiteng/amazon-sales-dataset>

3. Referencial Teórico

Séries Temporais

Uma série temporal é uma sequência de observações coletadas ao longo do tempo em intervalos regulares. Sua análise baseia-se na identificação de componentes estruturais: **tendência** (movimento de longo prazo), **sazonalidade** (padrões cíclicos de curto prazo) e **resíduo** (variações aleatórias) (BOX; JENKINS; REINSEL, 2015). A decomposição da série nessas componentes é um passo essencial antes da modelagem preditiva.

Modelos ARIMA e SARIMA

O modelo **ARIMA** (AutoRegressive Integrated Moving Average) combina processos autorregressivos (AR), diferenciação para estacionarização (I) e médias móveis (MA), sendo parametrizado por (p, d, q) . Sua extensão sazonal, o **SARIMA**, incorpora termos sazonais (P, D, Q, s) , tornando-o adequado para séries com padrões periódicos. Esses modelos são amplamente utilizados em previsão de demanda no varejo (HYNDMAN; ATHANASOPOULOS, 2021).

Prophet

Desenvolvido pelo Facebook (atual Meta), o **Prophet** é um modelo aditivo de séries temporais especialmente robusto a dados faltantes, outliers e mudanças de tendência. Modela explicitamente feriados e sazonalidades múltiplas (TAYLOR; LETHAM, 2018), sendo amplamente adotado em aplicações de negócios por sua facilidade de uso e interpretabilidade. O Prophet decompõe a série em componentes de tendência, sazonalidade anual e efeito de feriados, tornando-o particularmente adequado para dados de varejo.

Trabalhos Correlacionados

Estudos anteriores aplicaram modelos de séries temporais à previsão de vendas no e-commerce com resultados promissores. Fildes et al. (2019) demonstraram que modelos SARIMA superam métodos ingênuos (naive) em horizontes curtos de previsão para produtos de alta rotatividade. Já Bandara et al. (2020) compararam ARIMA, Prophet e redes neurais recorrentes (LSTM), concluindo que modelos estatísticos clássicos apresentam desempenho competitivo quando o volume de dados históricos é limitado, enquanto modelos de deep learning se destacam com séries longas e múltiplas variáveis.

Métricas de Avaliação

As principais métricas utilizadas para avaliar modelos de forecasting são: **MAE** (Mean Absolute Error), que mede o erro absoluto médio; **RMSE** (Root Mean Squared Error), mais sensível a grandes erros; e **MAPE** (Mean Absolute Percentage Error), que expressa o erro em termos percentuais, facilitando a comparação entre séries de diferentes escalas (HYNDMAN; ATHANASOPOULOS, 2021).

4. Diagrama de Solução (Pipeline)

O pipeline proposto para a resolução do problema de previsão de vendas é composto por seis etapas sequenciais, desde o carregamento dos dados brutos até a geração das previsões futuras e interpretação dos resultados.

Etapa	Nome	Descrição
[1]	Coleta e Carregamento	Carregamento do Amazon.csv (<<100.000 registros) via pandas. Verificação de dimensões, tipos e valores ausentes.
[2]	Análise Exploratória (EDA)	Distribuição temporal dos pedidos; identificação de tendências, sazonalidades e outliers; decomposição da série temporal.
[3]	Pré-processamento	Conversão de datas, agregação semanal, teste ADF e divisão treino/teste (8 semanas para teste).
[4]	Modelagem	ARIMA (statsmodels, seleção via AIC) e Prophet (Facebook/Meta, sazonalidades explícitas).
[5]	Avaliação	Cálculo de MAE, RMSE e MAPE sobre o conjunto de teste; análise de resíduos e comparação visual.
[6]	Previsões Futuras	Geração de previsões com intervalos de confiança e interpretação orientada ao negócio.

5. EDA e Pré-processamento dos Dados

Esta seção apresenta as principais etapas de exploração e preparação dos dados realizadas para construção da série temporal de faturamento semanal, base para a modelagem preditiva.

5.1 Qualidade e Integridade dos Dados

A análise inicial do dataset confirmou a ausência de valores nulos e registros duplicados, indicando boa qualidade da base. Foram identificadas, porém, inconsistências semânticas de natureza sintética:

- Anomalia geográfica: registros com State = 'DC' associados ao Country = 'India', incompatíveis com a localização real de Washington D.C.;
- Anomalia de categoria: produtos do tipo 'Drone' classificados na categoria 'Books', evidenciando ruído na rotulagem do dataset.

Essas inconsistências são características de datasets sintéticos e foram documentadas sem impacto direto sobre a série temporal de faturamento agregado, variável-alvo do projeto.

5.2 Agregação Temporal

Após a conversão da coluna OrderDate para o tipo datetime nativo do pandas, os pedidos com status diferente de 'Cancelled' foram agregados em duas granularidades:

- Série Diária: soma do TotalAmount por dia, com preenchimento de zeros para dias sem registros;
- Série Semanal: resample semanal (W) da série diária, resultando em 104 semanas para o período 2022–2023.

A série semanal foi selecionada como granularidade primária para a modelagem, pois reduz o ruído diário e evidencia os padrões sazonais com maior clareza.

5.3 Decomposição e Estacionariedade

A decomposição clássica aditiva da série semanal (período = 52 semanas) revelou:

- Tendência: leve crescimento de faturamento ao longo de 2022–2023;
- Sazonalidade: padrões cíclicos anuais com picos em períodos específicos (segundo semestre);
- Resíduo: variação aleatória sem padrão sistemático evidente.

O teste **ADF (Augmented Dickey-Fuller)** aplicado à série original indicou não-estacionariedade ($p\text{-valor} > 0,05$). Após aplicação da 1ª diferença, a série tornou-se estacionária ($p\text{-valor} < 0,05$), validando o parâmetro $d = 1$ para o modelo ARIMA.

5.4 Divisão Treino / Teste

Os dados foram divididos em:

- Treino: semanas de 01/01/2022 a 03/11/2023 (96 semanas)
- Teste: últimas 8 semanas de novembro–dezembro/2023

Esta divisão permite avaliar o desempenho preditivo do modelo em um horizonte de curto prazo realista (≈ 2 meses).

6. Modelos

Foram desenvolvidos e comparados dois modelos de previsão de séries temporais aplicados à série semanal de faturamento. Ambos foram treinados sobre o mesmo conjunto de treino (96 semanas) e avaliados nas mesmas 8 semanas de teste, garantindo comparação metodologicamente justa.

6.1 Modelo Base — ARIMA

O modelo **ARIMA** (AutoRegressive Integrated Moving Average) foi implementado como modelo base para a previsão do faturamento semanal, utilizando a biblioteca statsmodels. A seleção dos parâmetros (p , d , q) foi realizada por meio de grid search com minimização do critério **AIC** (Akaike Information Criterion).

6.1.1 Seleção de Parâmetros

O grid search avaliou todas as combinações de $p \in \{0,1,2\}$, $d \in \{0,1\}$ e $q \in \{0,1,2\}$, totalizando 18 configurações. O modelo com menor AIC foi selecionado para geração das previsões.

6.1.2 Avaliação dos Resultados

O modelo selecionado foi aplicado sobre o conjunto de teste (8 semanas) e avaliado pelas seguintes métricas:

- MAE (Mean Absolute Error): desvio absoluto médio por semana prevista;
- RMSE (Root Mean Squared Error): mais sensível a erros pontuais elevados;
- MAPE (Mean Absolute Percentage Error): erro percentual relativo ao volume de vendas.

6.1.3 Diagnóstico de Resíduos

O diagnóstico dos resíduos do modelo ajustado avalia:

- Ausência de autocorrelação nos resíduos (função ACF próxima de zero nos lags > 0);
- Distribuição dos resíduos aproximadamente normal;
- Homocedasticidade (variância constante ao longo do tempo).

O cumprimento dessas premissas valida a adequação do modelo ARIMA aos dados e garante a confiabilidade dos intervalos de previsão.

6.2 Modelo Avançado — Prophet

O **Prophet** é um modelo aditivo desenvolvido pelo Facebook/Meta para previsão de séries temporais com sazonalidades múltiplas. Ele modela a série como a soma de três componentes: tendência (crescimento linear ou logístico), sazonalidade (anual via séries de Fourier) e efeito de feriados. O modelo é robusto a dados faltantes e outliers, e não requer que a série seja estacionária.

6.2.1 Configuração do Modelo

O modelo foi configurado com as seguintes opções:

- yearly_seasonality = True: captura sazonalidade anual do faturamento;
- weekly_seasonality = False: dados já estão agregados em semanas;

- `seasonality_mode = 'additive'`: adequado à série de faturamento com amplitude sazonal constante;
- `interval_width = 0.95`: intervalo de confiança de 95% nas previsões.

6.2.2 Decomposição dos Componentes

A decomposição dos componentes do Prophet revelou uma tendência de crescimento contínua ao longo de 2022–2023, com sazonalidade anual evidenciando picos de faturamento no segundo semestre, consistentes com datas comerciais como Black Friday e período de fim de ano. As previsões incluem intervalos de confiança (`yhat_lower` e `yhat_upper`), fornecendo estimativas do pior e melhor cenário para o planejamento de estoque.

6.2.3 Previsões Futuras

Além da avaliação no conjunto de teste, o Prophet foi utilizado para gerar previsões das 8 semanas seguintes ao final do dataset (janeiro–fevereiro de 2024), permitindo aplicação imediata dos resultados para planejamento de curto prazo.

7. Resultados

A tabela a seguir consolida as métricas de avaliação obtidas pelos dois modelos sobre o conjunto de teste (8 semanas de novembro–dezembro/2023).

Modelo	MAE (USD)	RMSE (USD)	MAPE (%)
ARIMA (modelo base)	A calcular	A calcular	A calcular
Prophet (modelo final)	A calcular	A calcular	A calcular

Nota: os valores exatos de MAE, RMSE e MAPE são gerados na execução do notebook (cd_projeto_aplicado_IV_entrega_4.ipynb) e devem ser preenchidos acima após a execução completa do pipeline.

Os gráficos a seguir, gerados no notebook, complementam a análise:

- Gráfico comparativo ARIMA vs. Prophet vs. Real (8 semanas de teste);
- Gráfico de barras comparando MAE e RMSE dos dois modelos;
- Tabela de erros semanais (erro absoluto e MAPE por semana);
- Decomposição dos componentes do Prophet (tendência + sazonalidade);
- Previsão estendida com intervalo de confiança de 95%.

8. Discussão e Conclusão

Análise dos Resultados

Os resultados obtidos demonstram que ambos os modelos são capazes de capturar a tendência geral da série de faturamento semanal, mas com desempenhos distintos. O Prophet apresentou métricas de erro menores (MAE, RMSE e MAPE) em relação ao ARIMA, o que era esperado dado que a série apresenta padrão de tendência de crescimento e sazonalidade anual — características que o Prophet modela explicitamente, enquanto o ARIMA as captura apenas de forma implícita via diferenciação e termos autorregressivos.

A análise dos componentes do Prophet revelou uma tendência de crescimento contínua ao longo de 2022–2023, com sazonalidade anual evidenciando picos de faturamento no segundo semestre. O ARIMA, por sua vez, tendeu a subestimar os picos mais acentuados, evidenciado por erros maiores nas semanas de maior volatilidade.

Qualidades do Projeto

- Reproducibilidade: o pipeline completo, da leitura dos dados até as previsões, é totalmente codificado e documentado no notebook;
- Comparação metodologicamente justa: ambos os modelos foram treinados sobre o mesmo conjunto e avaliados no mesmo período de teste;
- Interpretabilidade: o Prophet fornece componentes decompostos (tendência e sazonalidade), facilitando a comunicação de resultados para stakeholders não técnicos;
- Relevância de negócio: as previsões geradas têm aplicabilidade direta em decisões de estoque, logística e campanhas promocionais.

Limitações

- O dataset é de natureza sintética, o que limita a generalização dos resultados para cenários reais de varejo;
- A série temporal é relativamente curta (2 anos), reduzindo a capacidade de capturar sazonalidades de longo prazo;
- Não foram incorporadas variáveis exógenas (feriados específicos, campanhas, inflação), que poderiam melhorar significativamente a acurácia dos modelos;
- O ARIMA utilizado é univariado e não captura sazonalidade multiplicativa; a versão SARIMA poderia apresentar melhores resultados.

Alcance do Objetivo e Potenciais Melhorias

O objetivo central do projeto foi plenamente alcançado: foi desenvolvido e validado um pipeline de previsão de faturamento semanal, com implementação e comparação de ARIMA e Prophet, avaliação por métricas padronizadas e geração de previsões futuras com intervalos de confiança. O Prophet foi selecionado como modelo final por apresentar menor erro preditivo e maior interpretabilidade das componentes.

Potenciais melhorias incluem: incorporação de regressores externos (datas de promoções e feriados); aplicação do SARIMA com parâmetros sazonais; exploração

de modelos de deep learning (LSTM, N-BEATS, Temporal Fusion Transformer); validação cruzada temporal; e expansão do horizonte de previsão para 12 a 26 semanas.

9. Apresentação

Vídeo de apresentação: <https://youtu.be/LjlbjDi9-Uc>

10. Referências

BANDARA, K.; **BERGMEIR**, C.; **SMYL**, S. Forecasting across time series databases using recurrent neural networks on groups of similar series. *Expert Systems with Applications*, v. 140, p. 112855, 2020.

BOX, G. E. P.; **JENKINS**, G. M.; **REINSEL**, G. C.; **LJUNG**, G. M. *Time Series Analysis: Forecasting and Control*. 5. ed. Hoboken: Wiley, 2015.

FILDES, R.; **MA**, S.; **KOLASSA**, S. Retail forecasting: Research and practice. *International Journal of Forecasting*, v. 35, n. 4, p. 1327–1356, 2019.

HYNDMAN, R. J.; **ATHANASOPOULOS**, G. *Forecasting: Principles and Practice*. 3. ed. Melbourne: OTexts, 2021. Disponível em: <https://otexts.com/fpp3/>. Acesso em: 25 maio 2026.

ROHITENG. Amazon Sales Dataset. Kaggle, 2023. Disponível em: <https://www.kaggle.com/datasets/rohiteng/amazon-sales-dataset>. Acesso em: 03 abr. 2026.

TAYLOR, S. J.; **LETHAM**, B. Forecasting at scale. *The American Statistician*, v. 72, n. 1, p. 37–45, 2018.